

中国地质大学
CHINA UNIVERSITY OF GEOSCIENCES
北京 · BEIJING

学术报告

AirFormer: Predicting Nationwide Air Quality in China with Transformers

《AirFormer：用 Transformer 预测空气质量》

汇 报 人：张筱琦

学　　号：2119240013

专　　业：应用统计

指导老师：王海英

汇报框架：从研究问题到方法证据，再到启发

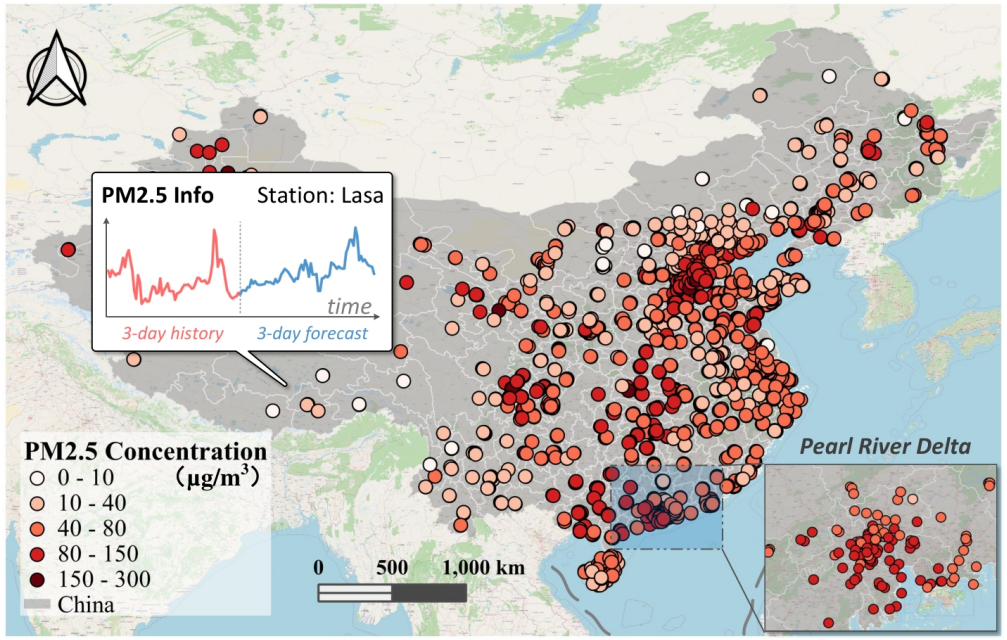
Liang 等，AAAI 2023 |NUS、京东、阿里达摩院、上海交通大学

01	研究背景	为什么值得研究?	P. 03
02	研究现状与不足	已有方法解决了什么，还缺什么?	P. 04–05
03	研究方法与过程	如何建模、训练与验证?	P. 06–16
04	研究结论	论文最终证明了什么?	P. 17
05	对中期研究的启发	AirFormer 如何引出我的中期研究?	P. 18–19

论文：AirFormer: Predicting Nationwide Air Quality in China with Transformers（PDF第2页）。

研究背景：从实时监测，走向全国细粒度预警

污染具有跨地扩散与时变特征；仅知道“现在怎样”，还不足以支持提前干预。



原文 Figure 1 | 全国 1,085 站点分布

1 社会需求

公众健康与出行预警
污染治理与应急决策

2 数据基础

全国站点持续监测
污染物读数 + 气象信息

3 科学问题

空间扩散与时间变化交织
需要多站点联合建模

研究目标：在全国范围，兼顾细粒度预测的效率与准确性。

来源：Introduction、Figure 1、Dataset Description（PDF第2–3、6页）。

研究现状：从物理机理到数据驱动时空模型

能力逐步增强，但“能建模时空关系”并不等于“能高效覆盖全国千站点”。

研究路线 / 代表	已具备的能力	全国尺度仍面临的不足
物理扩散模型	机理解释与过程模拟	多源输入精确获取困难
经典统计：HA / VAR	历史规律与线性依赖	复杂非线性关系刻画有限
DeepAir / 时空图网络	融合多源、学习时空关系	细粒度扩展需兼顾成本
注意力 / Transformer	动态关联、远近交互	全量空间 MSA 开销大

原文数据集规模对照

城市级样例

35 站

既有全国级样例

209 站

AirFormer

1,085 站

研究缺口：全国千站点场景下，时空表达能力、效率与不确定性仍需统筹。

来源：Related Works、Introduction、Table 1、References（PDF第2–3、7、9–11页）；按原文归纳。

研究不足：规模、时序结构与不确定性尚未统一

将文献不足转化为三个可检验的设计问题。

01

空间规模

标准空间 MSA：$O(N^2C)$

全国千站点的交互成本高

能否压缩远处空间信息？

DS-MSA

02

时间结构

时间局部性与因果顺序

需要在统一结构中利用

能否兼顾局部与长程依赖？

CT-MSA

03

数据不确定性

观测噪声 / 缺失

排放活动存在不可预测因素

能否学习随机潜在表示？

层级随机潜变量

AirFormer 的切入点：领域知识驱动的时空注意力 + 概率潜变量建模。

来源：Introduction、DS-MSA、CT-MSA、Top-Down Stochastic Stage（PDF第3–6页）。

研究过程：数据准备 → 模型设计 → 联合训练 → 实证检验

先明确预测对象，再建立结构，最后用对比、消融与案例逐层验证。

01

数据准备

站点筛选 / 时间切分
多变量历史 → PM2.5

02

模型设计

空间与时间注意力
层级随机潜变量

03

联合训练

预测 L1 损失
重构项 + KL 约束

04

实证检验

基线 / 消融 / 突变
注意力案例 / 参数敏感性

来源：Methodology、Experiments（PDF第4–9页）；根据论文组织研究流程。

数据与任务：1,085 站点，24 步预测未来 24 步

原始记录为小时级；实验中每个时间步为 3 小时。

1,976 → 1,085

PM2.5 缺失率 < 20%

342 城市 / 2,575 气象站

输入 $X_{1:24}$

历史 72 h × 1,085 站点

6 类污染物 + 气象变量

→

输出 $Y_{1:24}$

未来 72 h × 1,085 站点

PM2.5 浓度（$\mu g/m^3$）

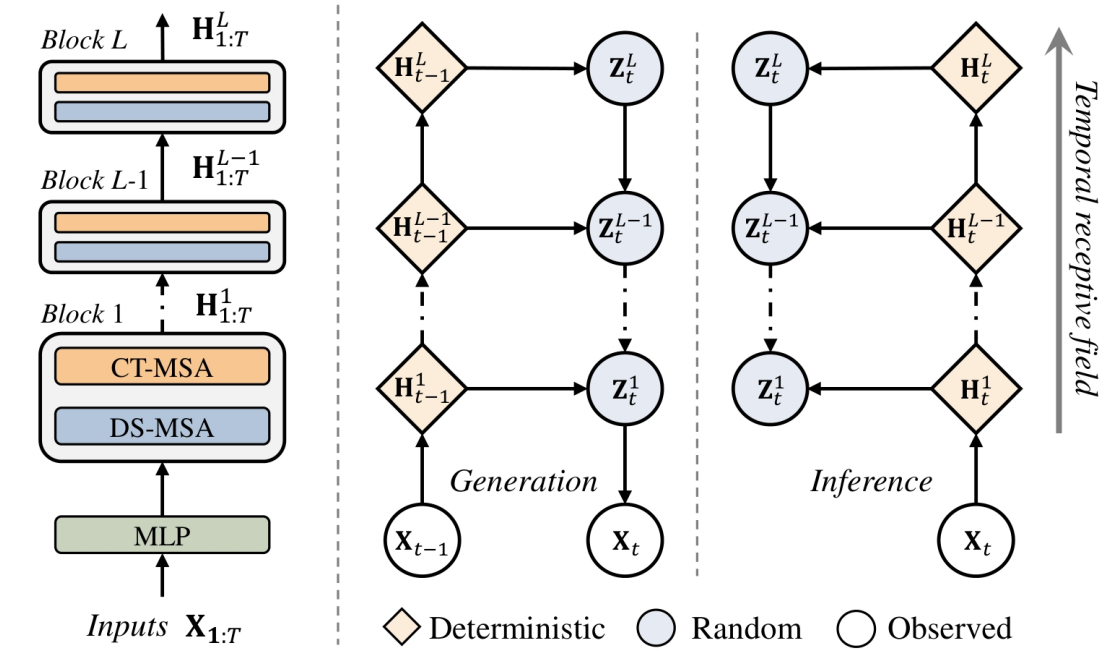
训练	验证	测试
2015—2016	2017	2018

按时间先后切分数据；既评估总体 MAE / RMSE，也单独评估突发变化。

来源：Problem Formulation、Dataset Description、Implementation Details（PDF第3、6–7页）。

总体架构：确定性表示学习 + 随机潜变量建模

用原文 Figure 3 看清模型的信息流：自底向上学习，自顶向下组织随机状态。



(a) Deterministic stage (b) Graphical view of the stochastic stage

1 确定性阶段

DS-MSA 学习空间关联

CT-MSA 学习时间依赖

2 随机阶段

高层 Z 向低层 Z 传递上下文

由 H 提供各层条件信息

3 联合输出

各层 H、Z 的末时刻状态

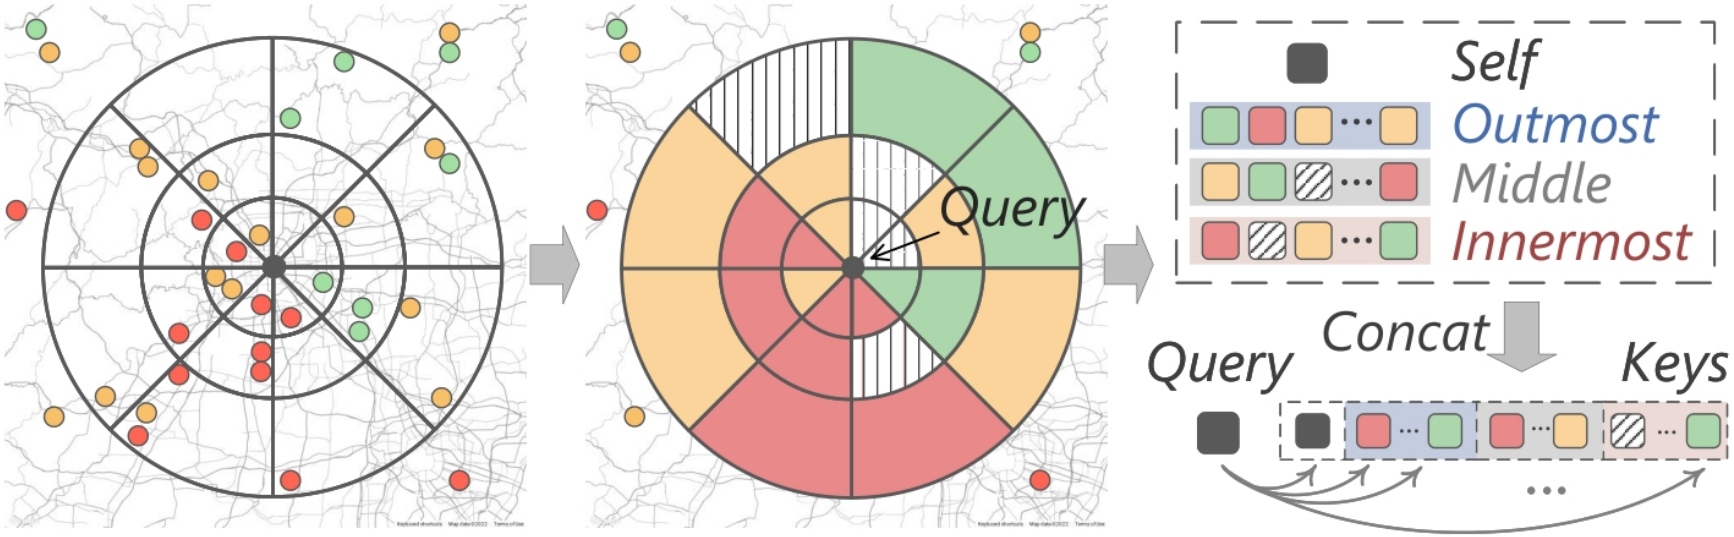
共同用于多步预测

阅读顺序：先看左侧“表示如何得到”，再看右侧“随机状态如何组织”。

来源：原文 Figure 3、Methodology（PDF第4页）。原图放大，中文解读另列。

空间建模：DS–MSA 将站点交互压缩为区域交互

核心先验：近处细粒度、远处粗粒度；用距离与方向组织注意力对象。



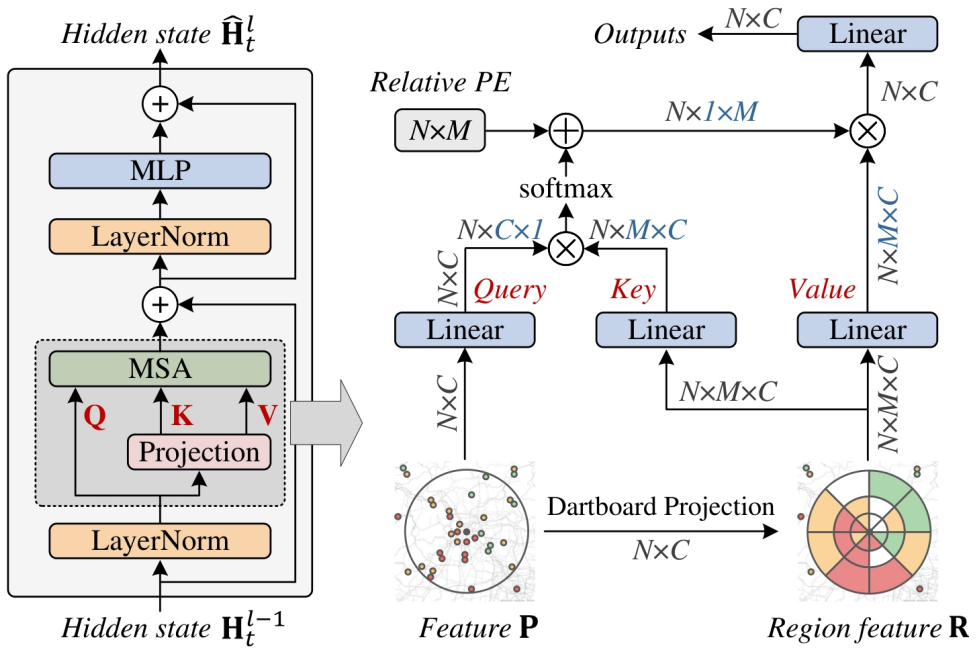
①空间分区　②区域聚合　③站点—区域注意力

原图三圈为示意；默认为 50 / 200 km 两圈，按相同方向划分得到 16 + 1 个表示。

来源：原文 Figure 2、DS–MSA、Implementation Details（PDF第3、5、7页）。

DS-MSA 计算过程：投影、位置编码与注意力

原文 Figure 4：左侧为模块结构，右侧展开空间投影和注意力计算。



1 区域投影

$R_i = A_i P$

同一区域的站点聚合为一个表示

2 构造 Q / K / V

Q 来自中心站点

K、V 来自区域表示

3 相对位置编码 + MSA

加入相对位置编码

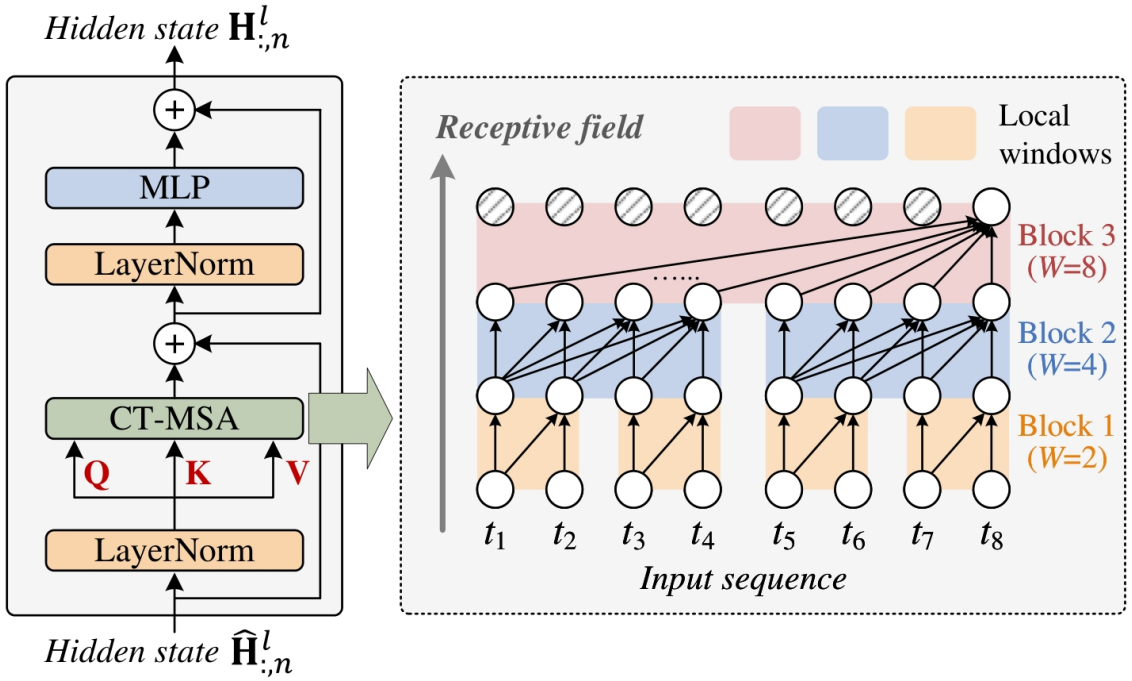
屏蔽无站点的区域

核心注意力：$O(N^2C) \rightarrow O(NMC)$，固定 M 时随 N 线性增长。

来源：原文 Figure 4、Eq. (4)–(5)、DS-MSA Discussion（PDF第5页）。

时间建模：CT-MSA 用局部窗口与因果约束学习依赖

原文 Figure 5：窗口逐层增大，形成从局部到长程的时间感受野。



1 局部性

同一层在非重叠窗口内计算
高层窗口覆盖更长历史

2 因果性

当前位置不读取更晚的输入
保持序列信息方向

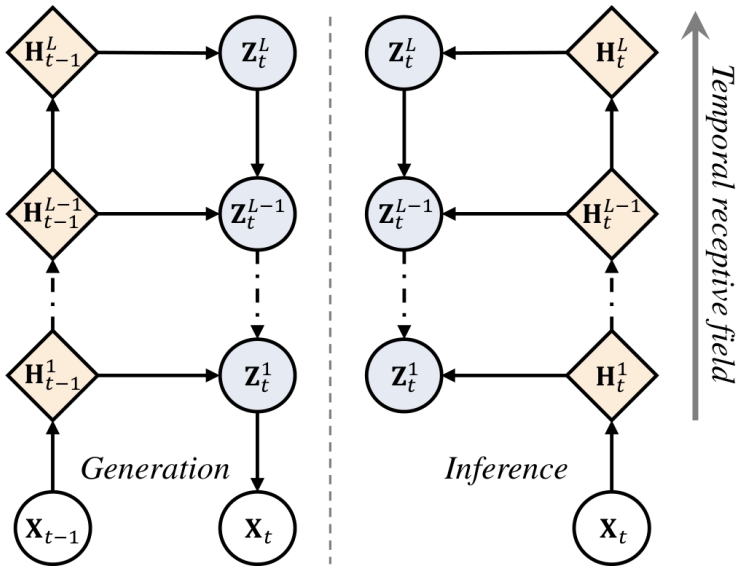
图中示意：2 → 4 → 8

默认 4 层窗口：3 → 6 → 12 → 24 步，即 9 → 18 → 36 → 72 小时。

来源：原文 Figure 5、CT-MSA、Implementation Details（PDF第5–7页）。

随机阶段：在层级潜在空间中表达不确定性

原文 Figure 3(b)：生成与推断使用不同历史条件，但共享层级组织方式。



(b) Graphical view of the stochastic stage

生成：先验 $p(Z_t \mid X_{1:t-1})$

仅以过去历史为条件

推断：后验 $q(Z_t \mid X_{1:t})$

可利用历史序列内部的当前观测

H：确定性表示　Z：高斯潜变量

高层携带长程上下文，低层融合局部信息。

层级潜变量改善表示能力；是否具有可靠概率输出，还需要额外校准评价。

来源：原文 Figure 3(b)、Eq. (6)–(8)（PDF第4、6页）。

训练与预测：多步输出，预测损失与负 ELBO 联合优化

用原文公式明确“输出怎么得到”和“模型怎样训练”。

预测输出

$$\hat{\mathbf{Y}}_{1:\tau} = \mathrm{MLP}([\mathbf{H}_T^1, \ldots, \mathbf{H}_T^L, \mathbf{Z}_T^1, \ldots, \mathbf{Z}_T^L]). \qquad (9)$$

各层末时刻状态拼接 → MLP → 未来 24 步

Lpred：预测损失

L1 误差

对齐未来 PM2.5

Lrec：重构项

重构历史观测

形成有效潜在表示

Lkl：分布约束

KL（后验 ‖ 先验）

约束潜在分布

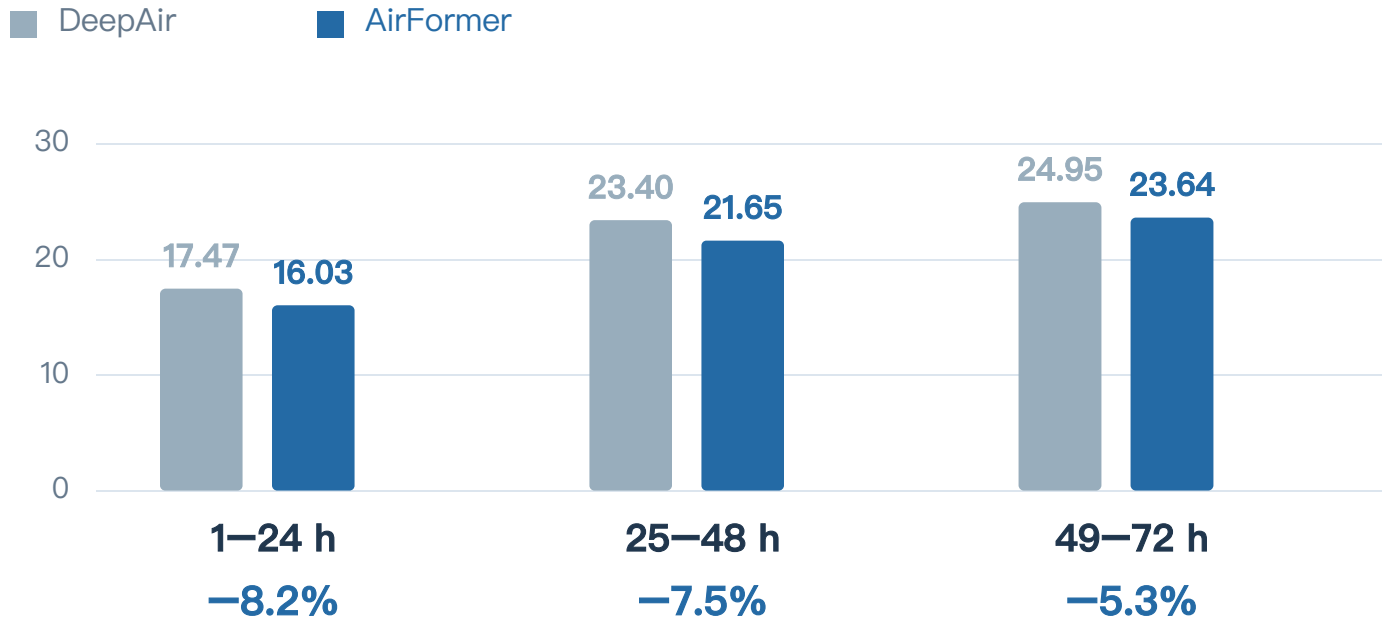
总目标：L = Lpred + Lrec + Lkl；负 ELBO 在历史时间步上累加。

来源：原文 Prediction & Optimization, Eq. (9)–(11)（PDF第6页）。

对比实验：常规区间与突发变化都获得更低误差

12 个基线、5 次运行均值；作者报告 t 检验显著性水平为 0.01。

分区间 MAE：DeepAir vs. AirFormer



突发变化（vs. MTGNN）

−7.3%

MAE：59.24 → 54.92

−13.1%

RMSE：103.71 → 90.15

PM2.5 > 75，未来 3 h 变化幅度 > 20

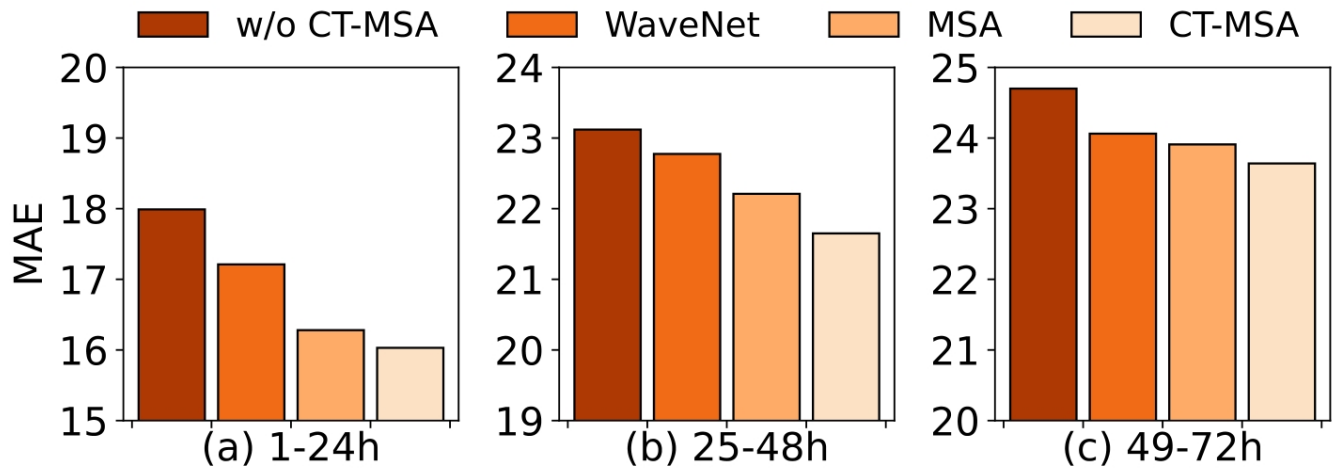
常规区间比较对象为 DeepAir；突发变化比较对象为 MTGNN，不能混用。

来源：原文 Table 2、Model Comparison（PDF第7–8页）。图表据原表数值绘制；单位 μg/m³。

消融实验：模块是否必要，收益来自哪里？

原文 Figure 7 展示时间模块对比；Table 3、4 给出空间与随机阶段证据。

时间模块消融 | 原文 Figure 7



CT–MSA 在三个区间中均优于其对比变体

空间效率

−39.4%

2,818 → 1,708 s / epoch

随机阶段

总体 MAE：20.97 → 20.44

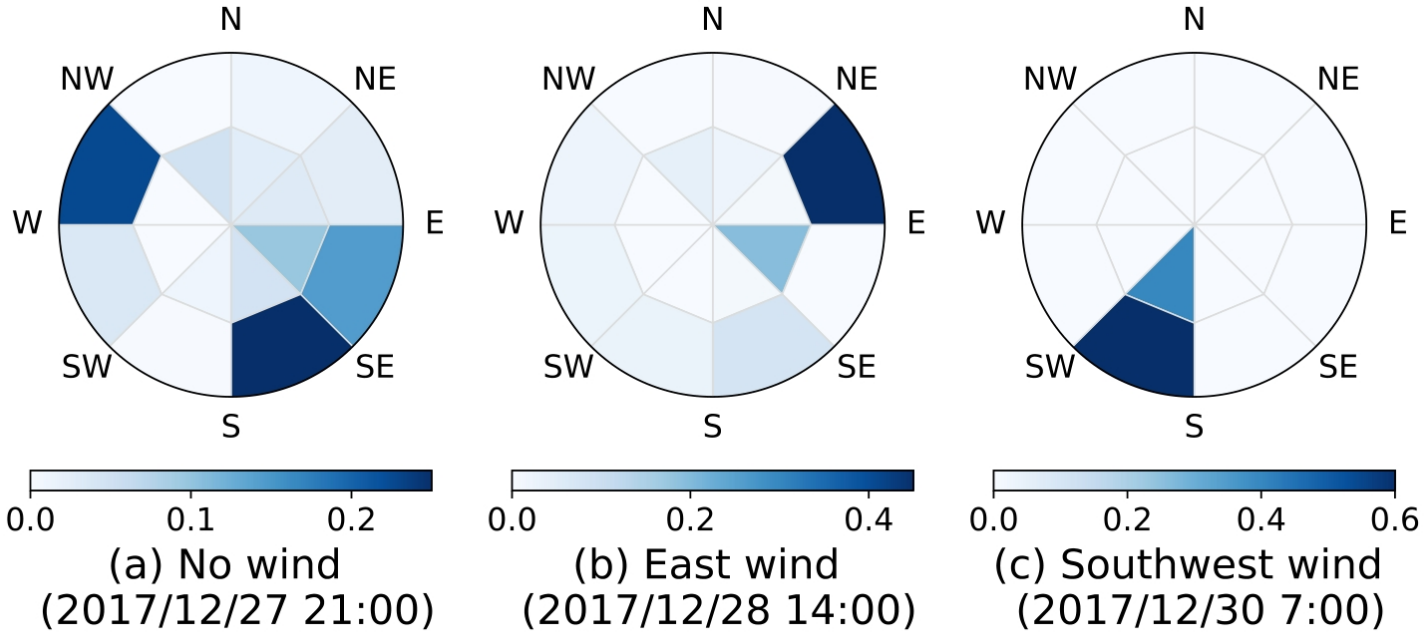
突变 MAE：57.52 → 54.92

消融回答“组件是否有效”；其结果不能替代概率校准或跨分布泛化检验。

来源：原文 Figure 7、Table 3、Table 4（PDF第8–9页）。

案例解释：空间注意力会随来风方向改变

北京西直门，2017 年 12 月 | 原文 Figure 6，展示第一层 DS-MSA。



无风：权重较分散

东风：更关注东侧

西南风：更关注西南侧

解释性证据：注意力行为符合领域直觉；仍不能把注意力权重当作因果效应。

来源：原文 Figure 6 与案例说明（PDF第8页）。各子图色标范围不同。

研究结论：在全国千站点预测中实现精度与效率的兼顾

把“作者提出了什么”与“实验支持了什么”分开归纳。

01

研究对象的扩展

1,085 个站点联合预测；过去 72 h → 未来 72 h 的 PM2.5。

02

模型结构的贡献

DS-MSA + CT-MSA + 层级随机潜变量，共同学习时空与随机表示。

03

实验结果的支撑

常规 MAE 相对 DeepAir 降低 5.3%–8.2%；突变、消融与效率结果提供补充证据。

核心结论：领域知识可以转化为有效结构，使大规模时空预测更准确、更高效。

来源：Conclusion、Table 2–4（PDF第8–9页）。首创性限定为作者陈述。

从 AirFormer 到 GeoAirFormer：继承与扩展

全国 1,085 站点 / 3 小时步长 → 京津冀 193 站点 / 逐小时观测

维度	AirFormer 已有基础	GeoAirFormer 的扩展设计（据中期稿）
空间	距离 / 方位分区与区域聚合 相对位置编码	GSE–MSA：距离邻接 + K 近邻关系 可学习融合后作为空间注意力偏置
时间	CT–MSA：因果注意力 多层窗口逐渐扩大	CrossAttn：短期 / 长期双分支 跨尺度交互 + 可学习时间衰减
任务	PM2.5 浓度预测 随机潜变量增强时空表示	浓度 / 等级 / 重污染预警联合建模 不确定性参数平衡多任务损失

八方位、因果与多尺度是继承基础；随机潜变量 ≠ 多任务不确定性损失权重。

研究启发：保留有效时空结构，围绕区域特征与预警需求扩展，再以消融检验贡献。

依据：AirFormer 原论文；GeoAirFormer 部分来自用户中期稿，未独立核验代码与实验文件。

中国地质大学
CHINA UNIVERSITY OF GEOSCIENCES
北京 · BEIJING

谢谢大家
请各位老师批评指正

备份：完整基线结果（5 次运行均值）

MAE / RMSE 的单位均为 μg/m³；AirFormer 行加星表示论文报告 0.01 水平显著。

Model	Param K	MAE①	RMSE①	MAE②	RMSE②	MAE③	RMSE③	突变 MAE	突变 RMSE
HA	—	31.25	62.52	31.19	62.49	31.16	62.49	72.89	132.42
VAR	—	29.91	52.10	31.61	64.59	30.18	65.10	70.86	114.78
DCRNN	397	19.35	46.40	24.06	57.38	25.30	58.24	63.22	112.30
STGCN	453	19.06	42.69	24.09	56.50	25.10	58.96	61.35	111.89
GWNET	825	17.79	39.49	23.32	53.17	25.00	57.01	59.33	105.75
MTGNN	207	18.15	38.99	23.47	52.21	24.77	55.73	59.24	103.71
ASTGCN	4,812	20.76	50.29	24.37	56.04	25.22	57.77	63.19	114.57
GMAN	269	19.60	45.70	23.79	54.25	24.89	56.33	61.83	109.57
STTN	188	18.22	37.44	24.16	52.91	25.35	56.14	60.36	105.20
DeepAir	183	17.47	39.12	23.40	53.48	24.95	56.92	60.26	109.95
PM2.5-GNN	101	20.20	48.96	25.04	59.56	26.31	60.46	63.64	119.00
GAGNN	412	19.53	45.68	24.56	58.59	25.56	59.61	64.38	116.51
AirFormer	**246**	**16.03***	**32.36***	**21.65***	**44.67***	**23.64***	**50.22***	**54.92***	**90.15***

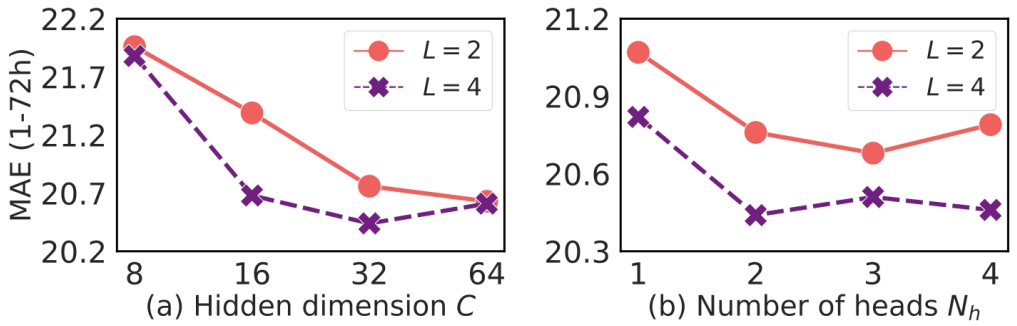
①1–24 h ②25–48 h ③49–72 h

来源：原文 Table 2（PDF第8页）。各区间不是单一预测时刻；原表没有报告标准差。

备份：参数敏感性与位置编码的原图证据

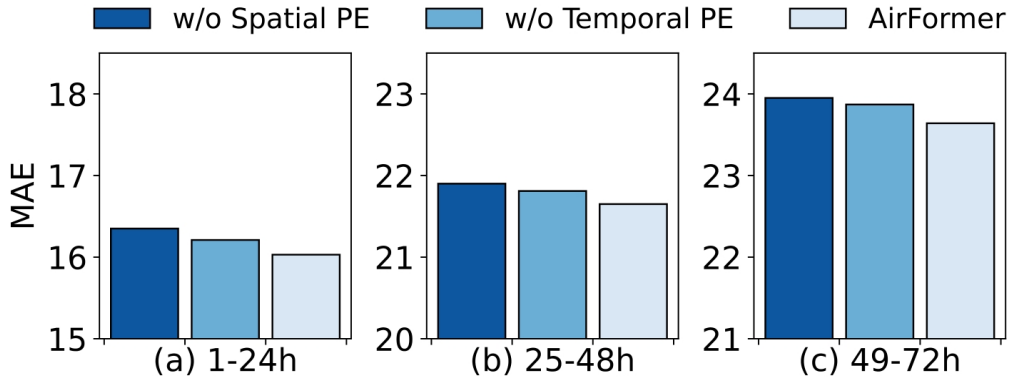
原文 Figure 8、9 | 回答“超参数如何选”“位置编码是否重要”时使用。

Figure 8 | 超参数敏感性



默认：L = 4, C = 32, heads = 2

Figure 9 | 位置编码消融



空间 / 时间位置编码均有贡献

原图保留完整坐标、图例与刻度；讨论趋势，不从图片估算额外的精确数值。

来源：原文 Figure 8、Figure 9、Implementation Details（PDF第7、9页）。